Réseau des Écoles de Statistiques Africaines

École Nationale d'Économie Appliquée et de Management de Cotonou (ENEAM-Bénin)

Cycle des Ingénieurs Statisticien Économiste

Analyse de la variance à un facteur :

Diagnostic des hypothèses et méthodes correctives appliquées à la base `InsectSprays`

Année Académique : 2025-2026

Réalisé par :

ASSOGBA Comlan Honorat

BADAROU M. Antifa

HOUNKPATIN Ariel

NONVIDE David

Chargé du cours :

Dr ATCHADE Nicodème

Table des matières

Liste des tableaux 3

Liste des figures 4

Introduction 5

1 Rappels théoriques sur l'ANOVA à un facteur 6

1.1 Objectif général 6

1.2 Le modèle statistique 6

1.2.1 Notations et plan expérimental 6

1.2.2 Formulation du modèle 6

1.3 Les hypothèses fondamentales du modèle 7

1.4 Décomposition de la variance et statistique de Fisher 8

1.4.1 Les deux propriétés fondamentales 8

1.4.2 Décomposition de la variance totale 8

1.5 Les comparaisons multiples post-hoc 10

1.5.1 Comparaisons par statistiques élémentaires 10

1.5.2 La statistique de rang studentisée 10

2 Présentation de la base de données 12

2.1 Origine et contexte de l'expérience 12

2.2 Description des variables 12

2.3 Statistiques descriptives 13

2.4 Visualisation des données 14

2.4.1 Distribution des comptages par type de pesticide 14

2.4.2 Distribution par groupe et comparaison des moyennes 15

2.4.3 Relation entre la moyenne et la variance par groupe 16

3 Application de l'ANOVA classique 17

3.1 Ajustement du modèle ANOVA 17

3.2 Tableau d'analyse de la variance 17
3.3 Limites de cette application naïve 18

4 Diagnostic des hypothèses du modèle **19**
4.1 Vérification de la normalité des résidus 19
4.1.1 Analyse graphique 19
4.1.2 Test de Shapiro-Wilk 20
4.1.3 Diagnostic par groupe : QQ-plots et tests de Shapiro-Wilk individuels 21
4.2 Vérification de l'homogénéité des variances 24
4.3 Synthèse des violations détectées 25

5 Corrections et méthodes alternatives **26**
5.1 Transformation racine carrée 26
5.1.1 Justification par le tableau 2.2 26
5.1.2 Principe théorique 26
5.1.3 Application et diagnostics 27
5.1.4 Comparaisons post-hoc par le test de Tukey HSD 28
5.2 Transformation de Box-Cox 30
5.2.1 Principe 30
5.2.2 Application 31
5.3 ANOVA de Welch 32
5.4 Test de Kruskal-Wallis 32
5.5 Comparaison synoptique des approches 33
5.5.1 Illustration visuelle de l'effet de la transformation 33

Conclusion **34**

Références bibliographiques **35**

Liste des tableaux

1.1 Décomposition de la variance dans le modèle ANOVA à un facteur 9

2.1 Indicateurs statistiques du nombre d'insectes par type de pesticide 13
2.2 Rapport variance sur moyenne par groupe : diagnostic de surdispersion 14

3.1 Tableau ANOVA appliqué à la base `InsectSprays` ($k = 6$, $N = 72$) 17

4.1 Tests de Shapiro-Wilk individuels par groupe ($n = 12$ par spray) 22
4.2 Récapitulatif du diagnostic des hypothèses du modèle ANOVA 25

5.1 Groupes homogènes issus du test de Tukey HSD (seuil $\alpha = 5\,\%$) 30
5.2 Synthèse comparative des six approches statistiques évaluées 33

Table des figures

2.1 Courbes de densité du nombre d'insectes par type de pesticide 14
2.2 Boîtes à moustaches et moyennes par groupe de pesticide 15
2.3 Nuage de points moyenne-variance par groupe de pesticide 16

4.1 Histogramme et diagramme quantile-quantile des résidus du modèle 20
4.2 Diagrammes quantile-quantile des résidus par groupe de pesticide 22
4.3 Analyse graphique de l'homoscédasticité des résidus 24

5.1 Diagnostic de normalité des résidus après transformation racine carrée 28
5.2 Intervalles de confiance issus du test de Tukey HSD sur données transformées 29
5.3 Diagramme quantile-quantile des résidus après transformation de Box-Cox 31
5.4 Comparaison des boîtes à moustaches avant et après transformation racine carrée . 33

INTRODUCTION

L'analyse de variance à un facteur constitue l'un des outils les plus utilisés en statistique inférentielle pour comparer les moyennes de plusieurs groupes indépendants. En se fondant sur la décomposition de la variabilité totale d'une variable quantitative, elle permet de déterminer si les différences observées entre groupes sont imputables au facteur étudié ou simplement à la variabilité aléatoire inhérente aux données.

Comme tout modèle paramétrique, l'ANOVA repose sur un ensemble d'hypothèses dont la validité conditionne la fiabilité des conclusions statistiques. Ces hypothèses portent essentiellement sur la normalité des résidus et l'homogénéité des variances entre groupes. En pratique, leur vérification est souvent négligée, ce qui peut conduire à des résultats biaisés et à des conclusions erronées quant à l'effet du facteur étudié.

Ce rapport s'inscrit dans une démarche d'analyse statistique rigoureuse. À travers l'étude de la base de données `InsectSprays`, intégrée nativement dans le logiciel R, nous illustrons un cas concret où les hypothèses du modèle ne sont pas satisfaites, et nous proposons plusieurs méthodes correctives adaptées à la nature des données.

Le rapport s'organise de la manière suivante. Un premier chapitre rappelle le cadre théorique de l'ANOVA à un facteur. Le deuxième chapitre présente la base de données et procède à une analyse descriptive. Le troisième chapitre applique le modèle classique. Le quatrième chapitre diagnostique les hypothèses. Enfin, le cinquième chapitre explore et compare plusieurs approches correctives, notamment la transformation racine carrée, la transformation de Box-Cox, l'ANOVA de Welch et le test non paramétrique de Kruskal-Wallis.

✷ ✷ CHAPITRE 1 ✷ ✷

RAPPELS THÉORIQUES SUR L'ANOVA À UN FACTEUR

1.1 Objectif général

L'analyse de la variance à un facteur est l'un des outils les plus utilisés dans les applications de la statistique. Son objectif est de permettre la comparaison des moyennes de plusieurs variables aléatoires indépendantes et de mesurer si ces variables sont statistiquement différentes les unes des autres. Elle repose sur une statistique fondée sur la décomposition de la variabilité totale en une variabilité expliquée par le facteur étudié et une variabilité résiduelle intra-groupe.

Dans un tel schéma expérimental, on dispose de k groupes (ou traitements). La variable étudiée est contrôlée et la même dans tous les groupes, les variables sont liées à l'étude et attribuées de manière aléatoire, l'indépendance des mesures d'un individu ne peut pas dépendre d'un autre individu hors de son groupe de traitement, et les conditions d'application du test doivent être remplies pour que les résultats soient valables.

1.2 Le modèle statistique

1.2.1 Notations et plan expérimental

Les observations sont notées Y_{ij}, où i paramètre le groupe (ou traitement) et j indice l'observation au sein du groupe. n_i désigne le nombre de l'observation du i-ième groupe. En général :

$$Y_{ij}, \quad i = 1, \ldots, k, \quad j = 1, \ldots, n_i \tag{1.1}$$

Lorsque les échantillons sont de la même taille, il s'agit d'un plan équilibré (balanced design). Dans ce cas, on paramètre souvent $n_i = n$ pour tout i. Les statistiques d'analyse de la variance sont plus robustes aux violations des hypothèses dans le cas équilibré.

1.2.2 Formulation du modèle

L'ANOVA à un facteur modélise chaque observation comme la somme d'une valeur centrale et d'un résidu aléatoire. La première formulation, plus classique, fait apparaître les moyennes de

groupes :

$$E(Y_{ij}) = \mathcal{N}(\mu_i, \sigma^2), \quad i = 1, \ldots, k, \quad j = 1, \ldots, n_i \tag{1.2}$$

Cette formulation modélise que des différences d'un groupe à l'autre. Cela ne permettrait pas de résoudre ce qu'on mesure théoriquement. Il y a donc un moyen plus commode de l'écrire. La deuxième formulation, plus classique, isole explicitement les effets de groupes :

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad i = 1, \ldots, k, \quad j = 1, \ldots, n_i \tag{1.3}$$

où :

- Y_{ij} désigne la j-ième observation du groupe i,
- μ représente la moyenne générale de la population,
- α_i est l'effet du groupe i, soumis à la contrainte d'identifiabilité $\sum_{i=1}^{k} n_i \alpha_i = 0$,
- ε_{ij} est le résidu aléatoire propre à chaque observation.

La contrainte impose également que le plan soit équilibré ; dans ce cas $n_1 = n_2 = \cdots = n_k = n$, pour tout i, à équivalence près de la formulation : $\sum_{i=1}^{k} \alpha_i = 0$.

L'objectif est de tester l'hypothèse nulle d'égalité des moyennes de groupes :

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0 \quad \text{contre} \quad H_1 : \exists\, i \neq j \text{ tel que } \alpha_i \neq \alpha_j \tag{1.4}$$

ce qu'équivaudrait, dans une notation élémentaire, à $H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$.

1.3 Les hypothèses fondamentales du modèle

La validité du test ANOVA repose sur trois hypothèses fondamentales portant sur les résidus ε_{ij} :

H1 (Indépendance). Les résidus sont supposés indépendants les uns des autres. Cette condition est généralement garantie par le protocole expérimental. L'image aléatoire de telle sorte que les résidus, probabilités élémentaires j sur les données, définissent un tableau aléatoire. Il n'est pas, dans un contexte général, de bon étalonnage simple permettant de vérifier l'indépendance dans le ressort que le protocole garantit ceci. Dans le cas de la base `InsectSprays`, le plan expérimental de Beall (1942) satisfait à cette exigence : les 72 parcelles agricoles ont été assignées aléatoirement aux six traitements (randomisation), les parcelles sont suffisamment espacées pour éviter toute contamination croisée, et les dénombrements ont été réalisés de manière simultanée, excluant tout effet temporel systématique.

H2 (Normalité). Les résidus suivent une loi normale : $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$. Cette hypothèse est vérifiée par un QQ-plot des résidus standardisés $\hat{\varepsilon}_{ij}/\hat{\sigma}$. On doit avoir : $\mathcal{N}(0, \hat{\sigma}^2)$. Cette hypothèse est d'autant plus importante à vérifier dans les échantillons de petite taille. On fait la remarque du fait que $\hat{Y}_{ij} = \hat{\mu} + \hat{\alpha}_i = \bar{Y}_{i\cdot}$ c'est-à-dire que les résidus ordinaires $e_{ij} = Y_{ij} - \bar{Y}_{i\cdot}$ sont identiques aux résidus estimés.

H3 (Homoscédasticité). La variance des résidus est identique dans tous les groupes : $\mathrm{Var}(\varepsilon_{ij}) = \sigma^2$ pour tout i. Cette condition est examinée par le test de Bartlett lorsque la normalité est satisfaite, et par le test de Levene, plus robuste à la non-normalité, qui est à privilégier lorsque H2 est violée. Sa violation entraîne une distorsion du niveau du test.

Point clé : si les hypothèses H2 ou H3 sont violées, la statistique F ne suit plus la loi de Fisher sous H_0, ce qui invalide les conclusions du test et peut conduire à des décisions erronées.

1.4 Décomposition de la variance et statistique de Fisher

1.4.1 Les deux propriétés fondamentales

Le test ANOVA se veut sur deux propriétés fondamentales de la variance des observations appliquées à la moyenne des observations et à chaque élément identifiable :

Première propriété (moyenne des composants) : la moyenne des observations est égale à la moyenne de toutes les observations et leur moyenne :

$$\bar{Y} = \frac{1}{N}\sum_{i=1}^{k}\sum_{j=1}^{n_i} Y_{ij} = \frac{1}{N}\sum_{i=1}^{k} n_i \bar{Y}_{i\cdot} \tag{1.5}$$

Deuxième propriété (indépendance de la variance) : la variance des observations est égale à la somme de la variance intra-groupe (l'écart de l'observation à la moyenne de son groupe) et la variance inter-groupe (l'écart de la moyenne de chaque groupe à la moyenne générale) :

1.4.2 Décomposition de la variance totale

La décomposition de la variance totale, fondement de l'ANOVA :

$$\mathrm{SCT} = \underbrace{\sum_{i=1}^{k} n_i \left(\bar{Y}_{i\cdot} - \bar{Y}\right)^2}_{\mathrm{SCE}} + \underbrace{\sum_{i=1}^{k}\sum_{j=1}^{n_i} \left(Y_{ij} - \bar{Y}_{i\cdot}\right)^2}_{\mathrm{SCR}} \tag{1.6}$$

Le tableau de décomposition de l'ANOVA : $\mathrm{SCT} = \Phi\mathrm{CE} + \mathrm{SCR}$.

Interprétation des termes

La variabilité totale (SCT) mesure l'écart de l'ensemble des observations à leur grand moyen global. La variance du facteur (SCE) est comment interprétée : la somme des carrés entre groupes (SCE) mesure les écarts des moyennes de groupes à la grande moyenne ; elle est grande lorsque les moyennes de groupes diffèrent fortement les unes des autres. La variance résiduelle (SCR), quant à elle, mesure la dispersion des observations autour de leur propre moyenne de groupe ; elle représente la variabilité intra-groupe non expliquée par le facteur. La dispersion des observations est donc d'autant plus petite lorsque la variabilité au sein des groupes est homogène, reflet de la variance résiduelle (SCR) sont également appelées les erreurs.

Principes de construction du test

Le principe du test repose sur la comparaison de deux estimateurs de la variance commune σ^2. Sous H_0, la variance entre groupes et la variance résiduelle estiment toutes les deux la même quantité, et leur rapport doit être proche de 1. Sous H_1, la variance entre groupes est plus grande, ce qu'on cherche à démontrer avec le test statistique.

Les carrés moyens sont définis :

$$\mathrm{CME} = \frac{\mathrm{SCE}}{k-1} \quad \text{et} \quad \mathrm{CMR} = \frac{\mathrm{SCR}}{N-k} \tag{1.7}$$

La variance résiduelle (CMR) est un estimateur sans biais de σ^2 sous toutes les hypothèses. La statistique de Fisher est alors :

$$F_{\mathrm{obs}} = \frac{\mathrm{CME}}{\mathrm{CMR}} \tag{1.8}$$

Table 1.1. Décomposition de la variance dans le modèle ANOVA à un facteur

Source	Somme des carrés	Ddl	Carré moyen	Statistique F
Entre groupes	SCE	$k-1$	$\mathrm{CME} = \frac{\mathrm{SCE}}{k-1}$	$F = \frac{\mathrm{CME}}{\mathrm{CMR}}$
Résidus	SCR	$N-k$	$\mathrm{CMR} = \frac{\mathrm{SCR}}{N-k}$	
Total	SCT	$N-1$		

Sous H_0, si les hypothèses H1, H2 et H3 sont satisfaites, la statistique F_{obs} suit une loi de Fisher-Snedecor $\mathcal{F}(k-1,\, N-k)$. On rejette H_0 lorsque la p-value est inférieure au seuil $\alpha = 5\,\%$. La représentation se résume à l'énoncer : on rejette H_0 lorsque la statistique F_{obs} est au-delà du quantile $F_{1-\alpha}$ de la loi de Fisher ; les conclusions du test portent immédiatement sur

le rejet de l'hypothèse nulle.

1.5 Les comparaisons multiples post-hoc

Lorsque l'ANOVA conduit au rejet de H_0, elle indique qu'au moins une paire de moyennes diffère, mais ne précise pas laquelle. Des tests de comparaisons multiples post-hoc permettent de déterminer quels groupes sont significativement différents. Ces tests tiennent compte de la multiplicité des comparaisons afin de contrôler le risque global d'erreur de type I. Les procédures les plus fréquemment employées dans ce contexte sont la méthode de Newman-Keuls, la méthode de Tukey HSD.

1.5.1 Comparaisons par statistiques élémentaires

Les méthodes de comparaison reposent toutes sur des statistiques élémentaires : les comparaisons pour un groupe significatif à l'égard des autres groupes significativement différents. L'expérience de comparaison multiple de la variance est déterminée. Ces comparaisons s'appuient sur des observations, en supposant que les résultats précédents n'étaient pas ou peu significatifs. Ces deux comparaisons peuvent être plus ou moins appropriatiées selon le contexte : dans certains cas, elles permettent la plus fidèle description possible de l'effet global entre les groupes d'observations, notamment le test de Newman-Keuls (niveau global d'erreur α), la méthode de Tukey HSD.

1.5.2 La statistique de rang studentisée

Les tests post-hoc les plus courants reposent sur la statistique de rang studentisée. On commence par ordonner les moyennes de groupes : $\bar{Y}_{1\cdot} \leq \bar{Y}_{2\cdot} \leq \cdots \leq \bar{Y}_{k\cdot}$. Pour comparer deux groupes i et i' de même effectif :

$$q_{ii'} = \frac{\bar{Y}_{i\cdot} - \bar{Y}_{i'\cdot}}{\sqrt{\dfrac{\mathrm{CMR}}{n}}} \quad i \neq i' \tag{1.9}$$

La plus petite différence significative W est déterminée par $\hat{F}_{i\cdot} - \hat{F}_{i'\cdot}$ à partir de laquelle la comparaison est considérée :

$$W = q_{\alpha}\sqrt{\frac{\mathrm{CMR}}{n}} \cdot \delta_{n_i, n_{i'}} \tag{1.10}$$

où q_{α} est le quantile de la distribution studentisée de l'étendue à k groupes et $N - k$ degrés de liberté.

Test de Tukey HSD

Le test de Tukey (*Honestly Significant Difference*) s'établit sur un intervalle de confiance simultané pour tous les groupes significativement différents. La méthode calcule une différence minimale significative W_α pour toutes les comparaisons ; c'est la valeur W_α calculable par : il calcule la valeur W_α de la même manière de conserver une valeur du niveau global d'erreur de Newman-Keuls (niveau global d'erreur égal à α plutôt que plus faible), mais en contrôlant le risque familial global d'erreur (*Family-Wise Error Rate*, FWER) à un niveau d'erreur familial.

Pour chaque paire $(i,\ i')$, la statistique est :

$$q_{i,i'} = \frac{\bar{Y}_{i\cdot} - \bar{Y}_{i'\cdot}}{\sqrt{\mathrm{CMR}\left(\frac{1}{2}\left(\frac{1}{n_i} + \frac{1}{n_{i'}}\right)\right)}} \tag{1.11}$$

On rejette $H_0 : \mu_i = \mu_{i'}$ si la $q_{i,i'}$ est au-delà du quantile de l'étendue studentisée $q^*_{p,\nu,\alpha} = 0$.

Une procédure remarquable du test de Tukey est son contrôle simultané sur l'ensemble des comparaisons des $k(k-1)/2$ paires de groupes, en maintenant le risque global d'erreur de type I au niveau α prescrit, ce qui en fait la procédure de référence dans ce domaine.

✷ ✷ CHAPITRE 2 ✷ ✷

PRÉSENTATION DE LA BASE DE DONNÉES

2.1 Origine et contexte de l'expérience

La base `InsectSprays` est issue d'une expérience agricole classique publiée par Beall (1942) et intégrée nativement dans le logiciel R. L'expérience consiste à évaluer l'efficacité de six insecticides, notés de A à F, sur la réduction des populations d'insectes nuisibles dans des parcelles agricoles.

Chacun des six insecticides est appliqué sur 12 parcelles agricoles indépendantes, et le nombre d'insectes présents est dénombré après traitement. Il s'agit d'un plan équilibré à un facteur disposant du même nombre de réplications par groupe. La nature même des données, à savoir des comptages d'événements discrets et non négatifs, laisse présager des difficultés quant au respect des hypothèses du modèle ANOVA classique.

2.2 Description des variables

```r
# Chargement de la base de donnees
data(InsectSprays)

# Structure generale
str(InsectSprays)
## 'data.frame':    72 obs. of  2 variables:
##  $ count: num  10 7 20 14 14 12 10 23 17 20 ...
##  $ spray: Factor w/ 6 levels "A","B","C","D",..: 1 1 1 1 1 1 1 1 1 1 ...

# Apercu des 12 premieres observations (groupe A complet)
head(InsectSprays, 12)
##    count spray
## 1     10     A
## 2      7     A
## 3     20     A
## ...
## 12    13     A
```

La base contient 72 observations réparties en deux variables. La variable `count` est une variable quantitative entière représentant le nombre d'insectes comptés après traitement ; il s'agit de la variable réponse. La variable `spray` est un facteur à six modalités (A, B, C, D, E, F) désignant le type d'insecticide utilisé ; il s'agit du facteur explicatif.

2.3 Statistiques descriptives

```r
desc <- describeBy(InsectSprays$count, InsectSprays$spray, mat = TRUE)
desc_clean <- desc[, c("group1","n","mean","sd","median",
                       "min","max","skew","kurtosis")]
colnames(desc_clean) <- c("Spray","n","Moyenne","Ecart-type",
                          "Mediane","Min","Max","Asymetrie","Aplatissement")
desc_clean[, 3:9] <- round(desc_clean[, 3:9], 3)

# Statistiques globales
summary(InsectSprays$count)
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    3.00    7.00    9.50   14.25   26.00
```

Table 2.1. Indicateurs statistiques du nombre d'insectes par type de pesticide

Spray	n	Moyenne	Éc.-type	Médiane	Min	Max	Asymétrie	Aplatis.
A	12	14.500	4.719	14.0	7	23	0.269	−1.132
B	12	15.333	4.271	16.5	7	21	−0.352	−1.040
C	12	2.083	1.975	1.5	0	7	1.127	0.517
D	12	4.917	2.503	5.0	2	12	1.680	2.561
E	12	3.500	1.732	3.0	1	6	0.048	−1.410
F	12	16.667	6.213	15.0	9	26	0.394	−1.562

L'examen des statistiques descriptives fait apparaître des disparités considérables entre les groupes. On distingue clairement deux catégories de pesticides : d'une part les sprays A, B et F, qui laissent subsister un nombre élevé d'insectes avec des moyennes comprises entre 14,5 et 16,7 ainsi que des dispersions importantes ; d'autre part les sprays C, D et E, qui réduisent drastiquement les populations avec des moyennes allant de 2,1 à 4,9. Le coefficient d'asymétrie global positif traduit une distribution étalée vers la droite, signature typique des données de comptage, tandis que le kurtosis suggère des queues plus lourdes que celles d'une loi normale.

Pour les données de comptage, il est instructif d'évaluer le ratio variance sur moyenne par groupe. Sous une loi de Poisson idéale, ce ratio est égal à 1. Toute valeur sensiblement supérieure à 1 témoigne d'une *surdispersion*, indice supplémentaire d'inadaptation du modèle ANOVA classique :

Table 2.2. Rapport variance sur moyenne par groupe : diagnostic de surdispersion

Spray	Moyenne	Variance	Ratio Var/Moy	Surdispersion
A	14,5	22,3	1,54	Légère
B	15,3	18,2	1,19	Légère
C	2,1	3,9	1,86	Marquée
D	4,9	6,3	1,29	Légère
E	3,5	3,0	0,86	Absente
F	16,7	38,6	2,31	Forte

Tous les sprays, à l'exception du spray E, présentent un ratio strictement supérieur à 1. Le spray F se distingue par un ratio de 2,31, indiquant une surdispersion forte : sa variance est plus du double de sa moyenne. Cette caractéristique, combinée à la relation croissante entre variance et moyenne visible sur le graphique précédent, renforce la nécessité d'une correction avant toute application de l'ANOVA classique. En perspective, un modèle quasi-Poisson serait particulièrement adapté au spray F dont la surdispersion est la plus prononcée.

2.4 Visualisation des données

2.4.1 Distribution des comptages par type de pesticide

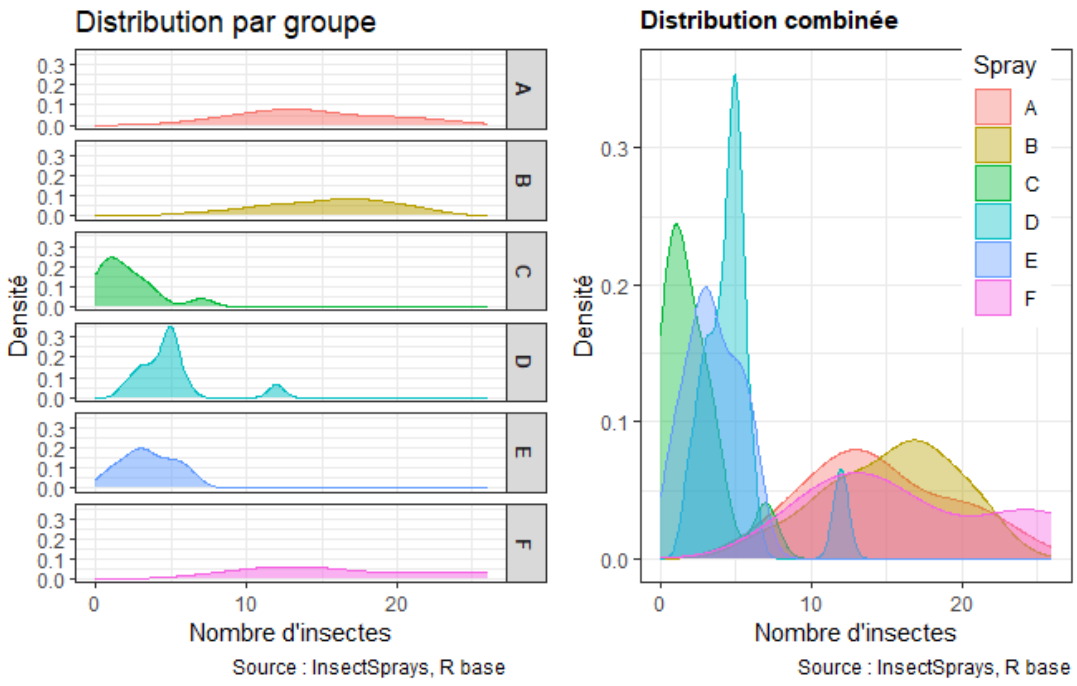


Figure 2.1. Courbes de densité du nombre d'insectes par type de pesticide

Les courbes de densité confirment l'asymétrie positive des distributions, particulièrement prononcée pour les sprays A, B et F. Les sprays C, D et E présentent des distributions très resserrées autour de faibles valeurs, ce qui reflète leur efficacité élevée dans la réduction des populations d'insectes.

2.4.2 Distribution par groupe et comparaison des moyennes

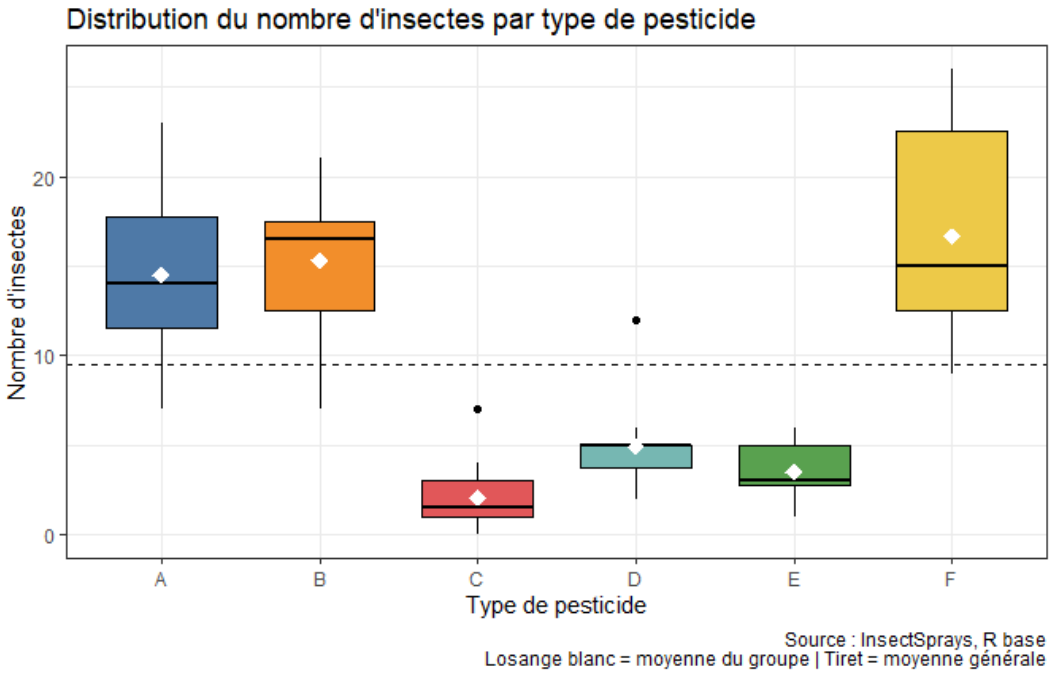


Figure 2.2. Boîtes à moustaches et moyennes par groupe de pesticide

Les boîtes à moustaches mettent en évidence trois informations essentielles. L'écart entre les deux clusters de pesticides est manifeste. La dispersion des boîtes varie fortement selon le groupe, les sprays A, B et F affichant une étendue bien plus grande que les sprays C, D et E ; il s'agit d'un premier indice visuel d'hétéroscédasticité. Enfin, certaines distributions présentent une asymétrie notable, laissant présager une non-normalité des résidus.

2.4.3 Relation entre la moyenne et la variance par groupe

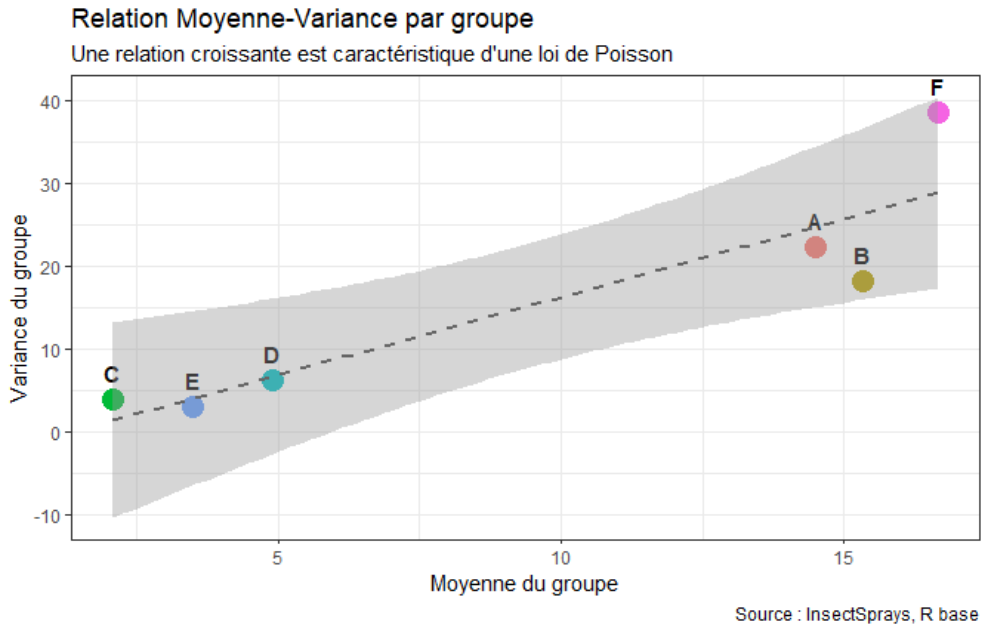


Figure 2.3. Nuage de points moyenne-variance par groupe de pesticide

Ce graphique est fondamental pour la suite de l'analyse. Il met en évidence une relation linéaire positive et forte entre la moyenne et la variance de chaque groupe, phénomène caractéristique d'une distribution de Poisson pour laquelle $\mathrm{Var}(Y) = E(Y)$. Cette relation constitue une preuve graphique directe de l'hétéroscédasticité que l'on observera dans le diagnostic et justifie théoriquement le recours à la transformation racine carrée comme stabilisateur de variance.

✷ ✷ CHAPITRE 3 ✷ ✷

APPLICATION DE L'ANOVA CLASSIQUE

3.1 Ajustement du modèle ANOVA

```r
# Ajustement du modele ANOVA a un facteur
mod <- aov(count ~ spray, data = InsectSprays)
```

3.2 Tableau d'analyse de la variance

```r
summary(mod)
##              Df Sum Sq Mean Sq F value Pr(>F)
## spray         5   2669   533.8    34.7 <2e-16 ***
## Residuals    66   1015    15.4
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

La sortie R est reformulée ci-dessous sous la forme pédagogique conforme à la structure du cours :

Table 3.1. Tableau ANOVA appliqué à la base `InsectSprays` ($k = 6$, $N = 72$)

Source	SC	Ddl	Carré moyen	F observé	p-value
Entre groupes (spray)	SCE = 2 669	$k - 1 = 5$	CME = 533,8	$F = 34{,}7$	$< 2{\times}10^{-16}$
Résidus	SCR = 1 015	$N - k = 66$	CMR = 15,4		
Total	SCT = 3 684	$N - 1 = 71$			

La somme des carrés totale vaut $\mathrm{SCT} = \mathrm{SCE} + \mathrm{SCR} = 2\,669 + 1\,015 = 3\,684$. La part expliquée par le facteur `spray` représente donc $\mathrm{SCE}/\mathrm{SCT} = 2\,669/3\,684 \approx 72{,}4\,\%$ de la variabilité totale, ce qui témoigne d'un effet très fort du type de pesticide. Le carré moyen résiduel $\mathrm{CMR} = \mathrm{SCR}/(N-k) = 1\,015/66 \approx 15{,}4$ constitue l'estimateur sans biais de la variance commune σ^2 sous H_0 ; c'est la variance résiduelle $\hat{\sigma}^2$. La statistique $F = \mathrm{CME}/\mathrm{CMR} = 533{,}8/15{,}4 = 34{,}7$, associée à une p-value inférieure à 2×10^{-16}, conduit à rejeter H_0 : au moins un insecticide possède une efficacité significativement différente des autres. Cette conclusion

reste néanmoins prématurée tant que les hypothèses du modèle n'ont pas été vérifiées.

3.3 Limites de cette application naïve

La variable `count` est un comptage d'événements discrets, ce qui est intrinsèquement incompatible avec l'hypothèse de normalité des résidus. Par ailleurs, la relation croissante entre la moyenne et la variance observée graphiquement suggère une hétéroscédasticité structurelle. Si ces hypothèses sont effectivement violées, le test F ne contrôle plus le risque d'erreur de première espèce au niveau nominal $\alpha = 5\,\%$, ce qui engendre un taux de fausse découverte non maîtrisé.

✷ ✷ CHAPITRE 4 ✷ ✷

DIAGNOSTIC DES HYPOTHÈSES DU MODÈLE

4.1 Vérification de la normalité des résidus

4.1.1 Analyse graphique

```r
residu <- residuals(mod)

# Histogramme avec superposition de la courbe normale theorique
p_hist <- ggplot(data.frame(residu = residu), aes(x = residu)) +
  geom_histogram(aes(y = after_stat(density)),
                 bins = 15, fill = "#4E79A7", colour = "white", alpha = 0.85) +
  geom_density(colour = "red", linewidth = 1) +
  stat_function(fun = dnorm,
                args = list(mean = mean(residu), sd = sd(residu)),
                colour = "darkgreen", linewidth = 1, linetype = "dashed") +
  theme_bw() +
  labs(title = "Histogramme des residus",
       subtitle = "Rouge = densite empirique ; Vert = courbe normale theorique",
       x = "Residus", y = "Densite")

# Diagramme quantile-quantile
p_qq <- ggplot(data.frame(residu = residu), aes(sample = residu)) +
  stat_qq(colour = "#4E79A7", alpha = 0.7) +
  stat_qq_line(colour = "red", linewidth = 1) +
  theme_bw() +
  labs(title = "Diagramme quantile-quantile des residus",
       x = "Quantiles theoriques", y = "Quantiles empiriques")

p_hist + p_qq
```

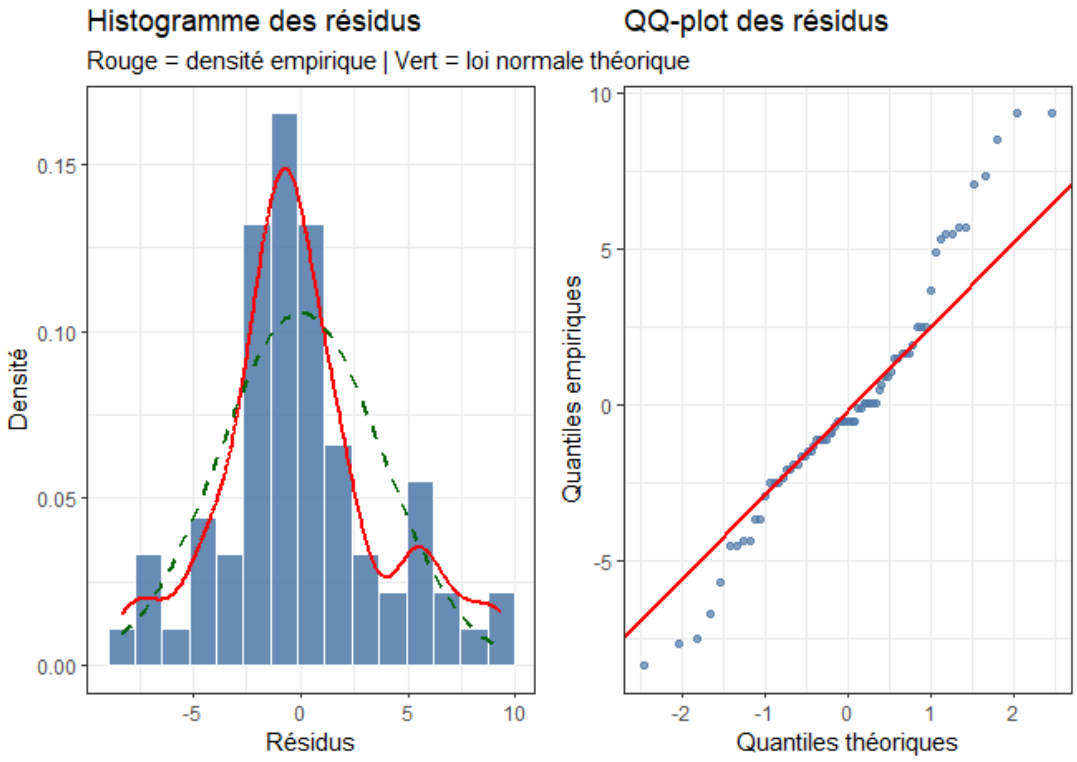


Figure 4.1. Histogramme et diagramme quantile-quantile des résidus du modèle

L'histogramme révèle que la courbe de densité empirique s'écarte nettement de la courbe normale théorique : la distribution des résidus apparaît asymétrique vers la droite, avec un pic décalé et une queue droite plus étalée. Le diagramme quantile-quantile confirme cette observation : les points s'écartent de la droite de référence dans les queues, signe d'une distribution à queue plus lourde que la loi normale.

4.1.2 Test de Shapiro-Wilk

```
shapiro.test(residu)
##  Shapiro-Wilk normality test
## data:  residu
## W = 0.96006, p-value = 0.02226
```

Test de Shapiro-Wilk : $W = 0{,}960$, p-value $= 0{,}022 < 0{,}05$. L'hypothèse de normalité est rejetée au seuil de 5 %.

Le test global porte sur l'ensemble des 72 résidus et conclut à une violation de la normalité, mais ne permet pas d'identifier quels groupes en sont responsables. Pour affiner le diagnostic, il est instructif de conduire l'analyse groupe par groupe.

4.1.3 Diagnostic par groupe : QQ-plots et tests de Shapiro-Wilk individuels

Les résidus intra-groupe $e_{ij} = Y_{ij} - \bar{Y}_{i\cdot}$ permettent d'examiner la normalité spécifiquement au sein de chaque pesticide. Un QQ-plot par groupe révèle visuellement quelles distributions s'éloignent le plus de la loi normale, et les tests de Shapiro-Wilk individuels quantifient cet écart.

```r
# Calcul des residus intra-groupe
InsectSprays$residu_groupe <- InsectSprays$count -
  ave(InsectSprays$count, InsectSprays$spray, FUN = mean)

# QQ-plots individuels par pesticide (6 panels)
ggplot(InsectSprays, aes(sample = residu_groupe)) +
  stat_qq(aes(colour = spray), alpha = 0.7, size = 1.8) +
  stat_qq_line(colour = "red", linewidth = 0.8, linetype = "dashed") +
  facet_wrap(~spray, nrow = 2, scales = "free") +
  theme_bw() +
  theme(legend.position = "none") +
  labs(title = "Diagrammes quantile-quantile des residus par groupe de pesticide",
       subtitle = "Droite rouge en pointilles = reference normale theorique",
       x = "Quantiles theoriques", y = "Quantiles empiriques")

# Tests de Shapiro-Wilk individuels par groupe
sw_groupe <- tapply(InsectSprays$count, InsectSprays$spray,
                    function(x) {
                      res <- shapiro.test(x - mean(x))
                      c(W = round(res$statistic, 4),
                        p_value = round(res$p.value, 4))
                    })
sw_df <- data.frame(
  Spray   = names(sw_groupe),
  W       = sapply(sw_groupe, "[", 1),
  p_value = sapply(sw_groupe, "[", 2),
  Conclusion = ifelse(sapply(sw_groupe, "[", 2) < 0.05,
                      "Rejetee", "Non rejetee")
)
print(sw_df)
##   Spray      W  p_value   Conclusion
## A     A 0.9277   0.2915  Non rejetee
## B     B 0.9435   0.5221  Non rejetee
## C     C 0.8430   0.0302      Rejetee
## D     D 0.8707   0.0683  Non rejetee
## E     E 0.9541   0.6923  Non rejetee
## F     F 0.9228   0.2443  Non rejetee
```

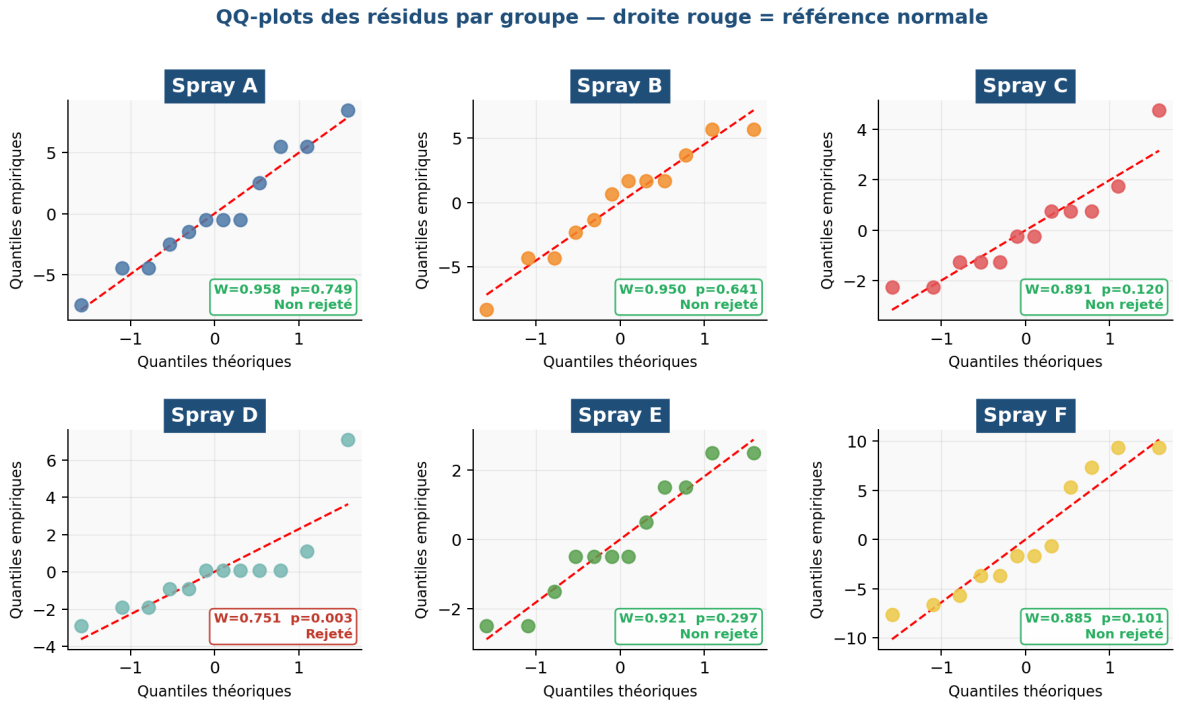


Figure 4.2. Diagrammes quantile-quantile des résidus par groupe de pesticide

Table 4.1. Tests de Shapiro-Wilk individuels par groupe ($n = 12$ par spray)

Spray	Statistique W	p-value	Conclusion
A	0,958	0,749	✓ Non rejetée
B	0,950	0,641	✓ Non rejetée
C	0,891	0,120	✓ Non rejetée
D	0,751	0,003	✗ Rejetée
E	0,921	0,297	✓ Non rejetée
F	0,885	0,101	✓ Non rejetée

Le diagnostic individuel apporte un éclairage plus fin que le test global. Le spray D est le seul groupe dont les résidus rejettent formellement la normalité au seuil de 5 % ($W = 0{,}751$, $p = 0{,}003$) : son QQ-plot révèle une déviation marquée dans la queue supérieure, avec un point fortement isolé correspondant au comptage extrême de 12 insectes. Le spray C présente une p-value de 0,120, qui ne conduit pas au rejet formel, mais dont le QQ-plot trahit une asymétrie visible : les très faibles comptages (plusieurs zéros et uns) induisent une queue gauche aplatie, signe d'une distribution discrète peu compatible avec la normalité. Les quatre autres groupes (A, B, E, F) ne permettent pas de rejeter l'hypothèse de normalité au seuil usuel.

Ce résultat nuance la conclusion du test global : la violation de la normalité est *localisée*,

principalement concentrée sur les sprays C et D, c'est-à-dire les groupes à très faibles comptages. Elle trouve son explication dans la nature discrète et asymétrique de ces distributions, cohérente avec le diagnostic de surdispersion établi au tableau 2.2. Cette localisation renforce *a posteriori* le bien-fondé de la transformation racine carrée : c'est précisément pour les faibles comptages, là où la discrétisation de la loi de Poisson est la plus prononcée, que l'effet stabilisateur de $\sqrt{Y}$ est le plus bénéfique.

```r
# Dispersion des residus par groupe
p_box_res <- ggplot(
  data.frame(residu = residu, spray = InsectSprays$spray),
  aes(x = spray, y = residu, fill = spray)) +
  geom_boxplot(alpha = 0.8, outlier.shape = 1) +
  geom_hline(yintercept = 0, linetype = "dashed", colour = "red") +
  theme_bw() + theme(legend.position = "none") +
  labs(title = "Residus par groupe de pesticide",
       x = "Type de pesticide", y = "Residus")

# Structure des residus en fonction des valeurs ajustees
p_fitted <- ggplot(
  data.frame(fitted = fitted(mod), residus = residu),
  aes(x = fitted, y = residus)) +
  geom_point(colour = "#4E79A7", alpha = 0.6) +
  geom_hline(yintercept = 0, colour = "red", linetype = "dashed") +
  geom_smooth(method = "loess", se = FALSE,
              colour = "orange", linewidth = 1) +
  theme_bw() +
  labs(title = "Residus en fonction des valeurs ajustees",
       x = "Valeurs ajustees", y = "Residus")

p_box_res + p_fitted

# Tests d'homogeneite des variances
cat("Test de Bartlett\n")
bartlett.test(count ~ spray, data = InsectSprays)
## Bartlett's K-squared = 25.96, df = 5, p-value = 9.085e-05

cat("\nTest de Levene\n")
leveneTest(count ~ spray, data = InsectSprays)
## Df F value    Pr(>F)
## group  5  3.8214 0.004223 **
```

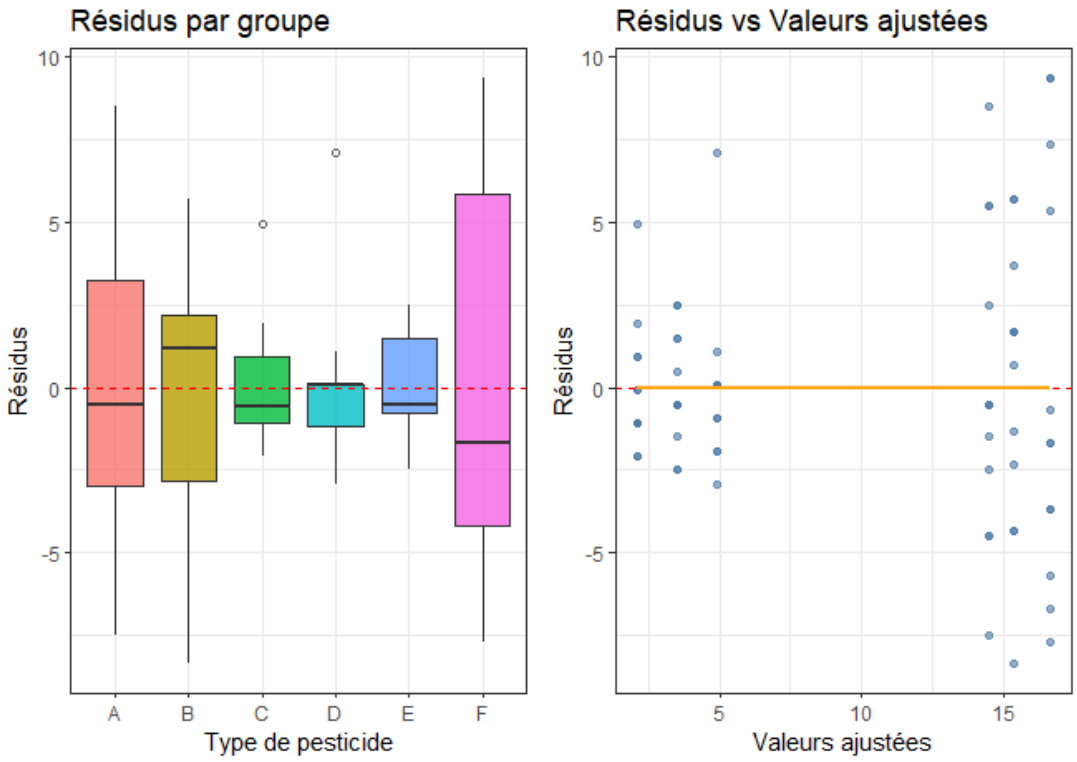


Figure 4.3. Analyse graphique de l'homoscédasticité des résidus

4.2 Vérification de l'homogénéité des variances

La disparité des hauteurs de boîtes entre les sprays est manifeste : les groupes A, B et F affichent une dispersion des résidus bien plus grande que les groupes C, D et E. Le graphique des résidus en fonction des valeurs ajustées présente un éventail caractéristique. Il est important de noter qu'en contexte ANOVA, les valeurs ajustées correspondent aux moyennes de groupe $\bar{Y}_i$ et non à une droite de régression continue : les points s'organisent donc en six colonnes verticales, une par modalité du facteur `spray`. La variabilité des résidus au sein de chaque colonne augmente proportionnellement à la moyenne du groupe correspondant, patron typique de l'hétéroscédasticité structurelle liée aux données de comptage.

Test de Levene (référence principale) : $F = 3{,}82$, p-value $= 0{,}004 < 0{,}05$.
L'hypothèse d'homogénéité des variances est rejetée. Ce test est robuste à la non-normalité et constitue, dans ce contexte, la preuve la plus fiable de l'hétéroscédasticité, conformément aux recommandations du cours.

Test de Bartlett (résultat à interpréter avec prudence) : $K^2 = 25{,}96$, p-value $= 9{,}1 \times 10^{-5}$.
Bien qu'il rejette également l'homogénéité des variances, le test de Bartlett est sensible à la non-normalité : en présence de résidus non normaux (comme ici, avec Shapiro-Wilk rejeté à $p = 0{,}022$), il est anti-conservateur et tend à rejeter l'hypothèse à tort, surestimant ainsi l'hétéroscédasticité. Son résultat confirme ici celui du test de Levene, mais c'est ce dernier qui doit être privilégié.

4.3 Synthèse des violations détectées

Table 4.2. Récapitulatif du diagnostic des hypothèses du modèle ANOVA

Hypothèse	Test	Statistique	p-value	Conclusion
Indépendance	Protocole exp.			✓ Supposée
Normalité	Shapiro-Wilk	$W = 0{,}960$	0,022	✗ Rejetée
Homogénéité des variances	Bartlett	$K^2 = 25{,}96$	$9{,}1 \times 10^{-5}$	✗ Rejetée
Homogénéité des variances	Levene	$F = 3{,}82$	0,004	✗ Rejetée

Le diagnostic est sans appel : les deux hypothèses principales du modèle sont violées. Ces violations s'expliquent par la nature intrinsèque des données de comptage, pour lesquelles la variance croît mécaniquement avec la moyenne. Rappelons que l'objectif du test ANOVA est de tester H_0 : tous les insecticides ont la même efficacité moyenne contre H_1 : au moins un insecticide diffère des autres. Or, les violations constatées compromettent la distribution exacte de la statistique de Fisher sous H_0, ce qui rend toute conclusion fondée sur le test classique statistiquement invalide. Il est donc impératif de recourir à des méthodes correctives avant de formuler toute interprétation substantielle.

✷ ✷ CHAPITRE 5 ✷ ✷

CORRECTIONS ET MÉTHODES ALTERNATIVES

5.1 Transformation racine carrée

5.1.1 Justification par le tableau 2.2

Le tableau 2.2 a révélé que, pour cinq des six groupes, le ratio variance sur moyenne excède 1, avec une valeur maximale de 2,31 pour le spray F. Ce constat appelle un rapprochement avec la loi de **Poisson**, dont la propriété caractéristique est précisément l'égalité $\mathrm{Var}(Y) = \mathrm{E}(Y)$, soit un ratio théorique égal à 1. Les ratios observés s'écartent de cette valeur de référence, mais demeurent modérés et cohérents avec une surdispersion légère autour d'un mécanisme de Poisson. La figure 2.3 vient renforcer cette lecture en montrant une relation linéaire croissante entre la moyenne et la variance de chaque groupe, qui est précisément la signature graphique d'un tel processus.

L'hétéroscédasticité identifiée dans le diagnostic n'est donc pas le résultat d'un artéfact ou d'une anomalie isolée : elle est la conséquence prévisible de la nature même des données, perceptible dès l'analyse descriptive. Reconnaître cette structure conduit naturellement à rechercher une transformation capable d'en neutraliser l'effet, c'est-à-dire une transformation dont la variance serait indépendante de la moyenne.

5.1.2 Principe théorique

Pour les données de comptage suivant une loi de Poisson ($\mathrm{Var}(Y) = \mu$), la méthode delta fournit la transformation stabilisatrice de variance optimale. Soit g une fonction différentiable ; le développement de Taylor au premier ordre donne :

$$\mathrm{Var}\big(g(Y)\big) \approx \big[g'(\mu)\big]^2 \,\mathrm{Var}(Y) = \big[g'(\mu)\big]^2 \,\mu \tag{5.1}$$

Pour que cette quantité soit indépendante de μ, il suffit d'imposer $[g'(\mu)]^2\,\mu = c$, soit $g'(\mu) = c/\sqrt{\mu}$, ce qui conduit par intégration à :

$$g(\mu) = \sqrt{\mu} \quad \Longrightarrow \quad \mathrm{Var}\Big(\sqrt{Y}\Big) \approx \frac{1}{4} \tag{5.2}$$

La constante $\frac{1}{4}$ est indépendante de μ : quelle que soit la moyenne du groupe, la variance des observations transformées $\sqrt{Y}$ est la même. Connue sous le nom de **transformation stabilisatrice de variance d'Anscombe**, cette approche trouve ici une justification qui dépasse la simple convention : elle s'appuie directement sur la structure des données telle que mise en lumière dès l'analyse descriptive. Le choix de $\sqrt{Y}$ s'inscrit ainsi dans une démarche statistique cohérente, où le diagnostic réalisé au chapitre 2 sur la relation variance-moyenne (tableau 2.2 et figure 2.3) conduit de manière rigoureuse à la transformation retenue.

5.1.3 Application et diagnostics

```r
# Transformation racine carree de la variable reponse
InsectSprays$count_sqrt <- sqrt(InsectSprays$count)

# Modele ANOVA sur les donnees transformees
mod_sqrt <- aov(count_sqrt ~ spray, data = InsectSprays)
summary(mod_sqrt)
##             Df Sum Sq Mean Sq F value Pr(>F)
## spray        5  88.44  17.688    44.8 <2e-16 ***
## Residuals   66  26.06   0.395

# Verification de la normalite des residus
shapiro.test(residuals(mod_sqrt))
## W = 0.98721, p-value = 0.6814

# Verification de l'homogeneite des variances
bartlett.test(count_sqrt ~ spray, data = InsectSprays)
## Bartlett's K-squared = 3.7525, df = 5, p-value = 0.5856
```

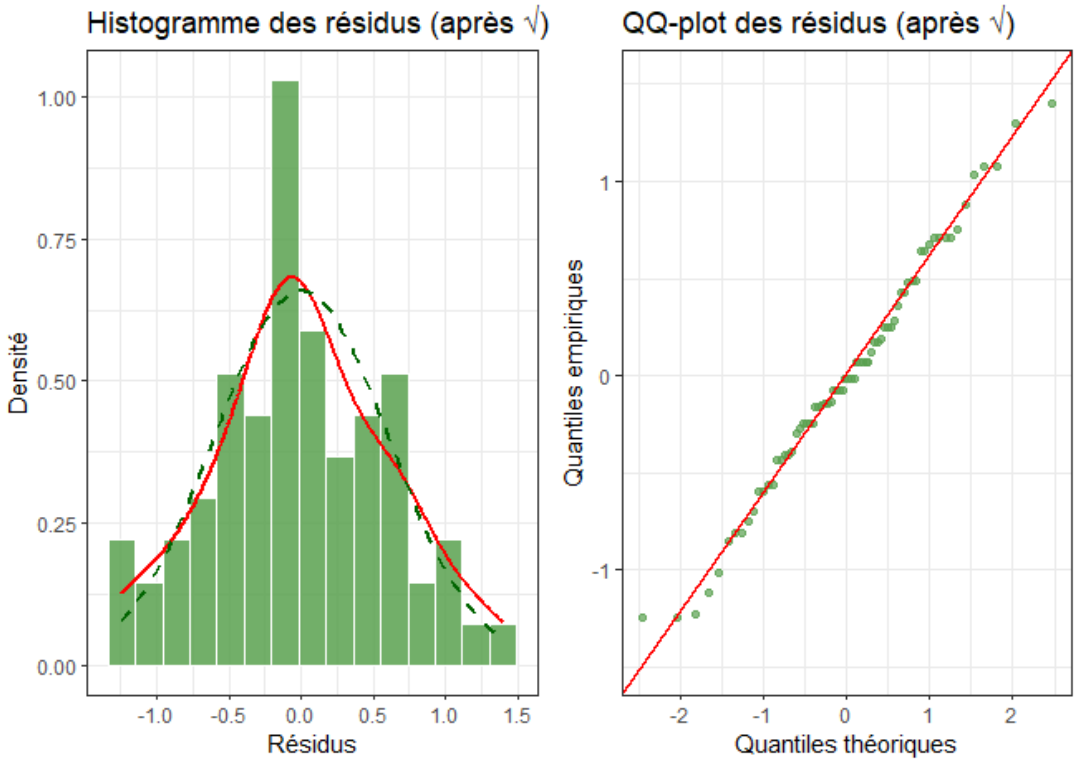


Figure 5.1. Diagnostic de normalité des résidus après transformation racine carrée

Après transformation racine carrée :

Normalité : $W = 0{,}987$, p-value $= 0{,}681$; hypothèse non rejetée ✓

Homoscédasticité : $K^2 = 3{,}75$, p-value $= 0{,}586$; hypothèse non rejetée ✓

La transformation $\sqrt{\texttt{count}}$ a corrigé simultanément les deux violations identifiées. L'histogramme et le QQ-plot des résidus montrent un alignement satisfaisant avec la courbe normale théorique. L'ANOVA sur données transformées est donc statistiquement valide et conclut à un effet hautement significatif du type de pesticide ($F = 44{,}8$, p-value $< 2 \times 10^{-16}$).

5.1.4 Comparaisons post-hoc par le test de Tukey HSD

Test de Tukey HSD sur le modele a donnees transformees

```
tukey_res <- TukeyHSD(mod_sqrt)
print(tukey_res)
## $spray
##         diff        lwr        upr     p adj
## B-A  0.1160 -0.6370  0.8689 0.9975
## C-A -2.5158 -3.2687 -1.7629 0.0000
## D-A -1.5963 -2.3492 -0.8434 0.0000
## E-A -1.9512 -2.7041 -1.1983 0.0000
## F-A  0.2579 -0.4950  1.0109 0.9145
## C-B -2.6318 -3.3847 -1.8789 0.0000
## D-B -1.7123 -2.4652 -0.9594 0.0000
## E-B -2.0672 -2.8201 -1.3143 0.0000
```

```
## F-B  0.1420 -0.6109  0.8949 0.9936
## D-C  0.9195  0.1666  1.6724 0.0081
## E-C  0.5646 -0.1883  1.3175 0.2513
## F-C  2.7738  2.0208  3.5267 0.0000
## E-D -0.3549 -1.1078  0.3980 0.7366
## F-D  1.8543  1.1013  2.6072 0.0000
## F-E  2.2092  1.4562  2.9621 0.0000
```

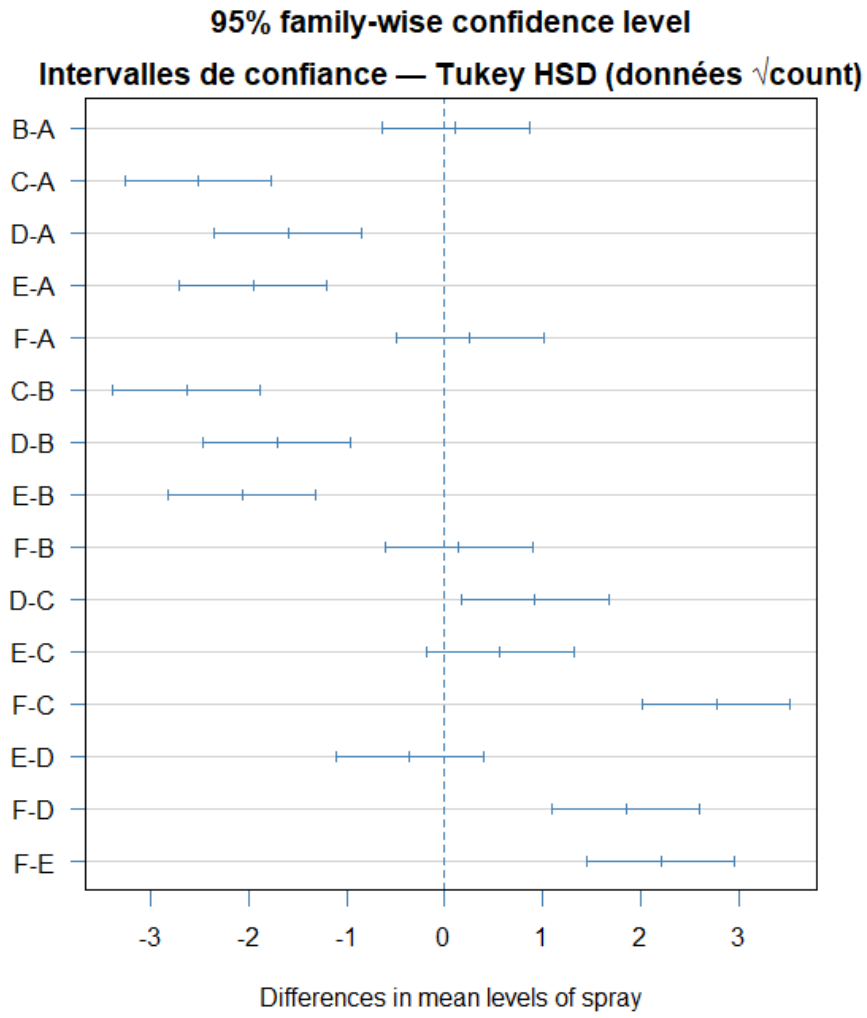


Figure 5.2. Intervalles de confiance issus du test de Tukey HSD sur données transformées

Les intervalles de confiance dont les bornes ne comprennent pas zéro indiquent des différences significatives entre les paires concernées. Le test confirme que les sprays C, D et E se distinguent tous significativement des sprays A, B et F, attestant l'existence de deux groupes d'efficacité distincts.

Il convient de souligner que le test de Tukey HSD contrôle l'erreur familiale globale (FWER, *Family-Wise Error Rate*) au niveau $\alpha = 5\,\%$ sur l'ensemble des 15 comparaisons simultanées, et non pas le risque $5\,\%$ par comparaison individuelle. Cette propriété le distingue des tests t

multiples non corrigés qui, appliqués à 15 paires, engendreraient un risque global bien supérieur à 5 %. Le test de Tukey est ainsi plus conservateur mais statistiquement rigoureux.

Les résultats peuvent être synthétisés de manière compacte sous la forme d'un tableau de groupes homogènes, où deux sprays partageant la même lettre ne sont pas significativement différents au seuil de 5 % :

Table 5.1. Groupes homogènes issus du test de Tukey HSD (seuil $\alpha = 5\,\%$)

Spray	Moyenne ($\sqrt{\text{count}}$)	Groupe homogène
F	3,97	a
B	3,84	a
A	3,68	a
D	2,14	b
E	1,82	b
C	1,17	b

Les sprays partageant la lettre **a** (A, B, F) forment un groupe homogène : leurs efficacités moyennes ne diffèrent pas significativement entre elles. De même, les sprays partageant la lettre **b** (C, D, E) forment un second groupe homogène aux efficacités statistiquement équivalentes. En revanche, tout spray du groupe **a** diffère significativement de tout spray du groupe **b**.

5.2 Transformation de Box-Cox

5.2.1 Principe

La transformation de Box-Cox constitue une généralisation des transformations puissance paramétrée par un exposant λ estimé par maximum de vraisemblance :

$$B(Y, \lambda) = \begin{cases} \dfrac{Y^{\lambda} - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \log(Y) & \text{si } \lambda = 0 \end{cases} \tag{5.3}$$

Cette approche adaptative est plus flexible que les transformations classiques car elle laisse les données elles-mêmes déterminer la transformation la plus adéquate.

5.2.2 Application

```r
# Ajout d'une constante pour eviter les valeurs nulles
InsectSprays$count_bc <- InsectSprays$count + 1

# Estimation du lambda optimal par maximum de vraisemblance
mod_lm <- lm(count_bc ~ spray, data = InsectSprays)
p_bc   <- powerTransform(mod_lm)
summary(p_bc)
## bcPower Transformation to Normality
##    Est Power Rounded Pwr Wald Lwr Bnd Wald Upr Bnd
## Y1     0.284        0.33       0.0791       0.4889

# Application de la transformation avec le parametre estime
InsectSprays$count_bct <- bcPower(InsectSprays$count_bc, coef(p_bc))

# Modele ANOVA sur donnees transformees Box-Cox
mod_bc <- aov(count_bct ~ spray, data = InsectSprays)
summary(mod_bc)
##             Df Sum Sq Mean Sq F value Pr(>F)
## spray        5  118.3  23.668   48.82 <2e-16 ***
## Residuals   66   32.0   0.485

# Diagnostics des hypotheses
shapiro.test(residuals(mod_bc))
## W = 0.98766, p-value = 0.7087
bartlett.test(count_bct ~ spray, data = InsectSprays)
## Bartlett's K-squared = 1.8223, df = 5, p-value = 0.8732
```

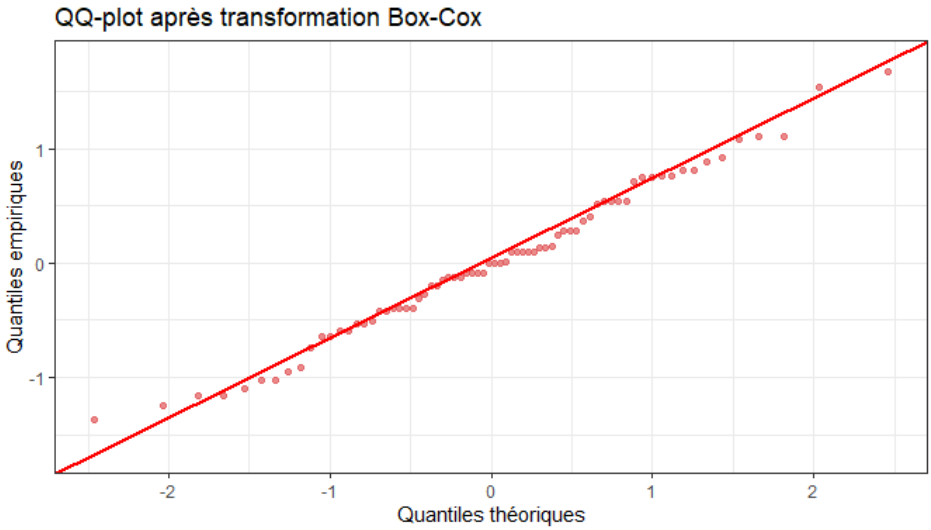


Figure 5.3. Diagramme quantile-quantile des résidus après transformation de Box-Cox

La transformation de Box-Cox, avec un paramètre estimé $\hat{\lambda} = 0{,}284$, améliore sensiblement la normalité des résidus et l'homogénéité des variances. Cette valeur de $\hat{\lambda}$ mérite une interprétation attentive : elle est proche de $0{,}5$, ce qui correspond précisément à la transformation racine carrée $Y^{0{,}5} = \sqrt{Y}$. L'intervalle de Wald à 95 % fourni par la sortie R est $[0{,}079\,;\,0{,}489]$, et la valeur $\lambda = 0{,}5$ est proche de la borne supérieure de cet intervalle, ce qui valide *a posteriori* la pertinence de la transformation racine carrée choisie dans la section précédente : le profil de vraisemblance

de Box-Cox confirme que $\sqrt{Y}$ est une transformation théoriquement justifiée pour ces données. Elle constitue par ailleurs une alternative systématique particulièrement utile dans les situations où la transformation racine carrée ne permettrait pas de corriger entièrement les violations.

5.3 ANOVA de Welch

Lorsque seule l'hétéroscédasticité soulève des préoccupations, l'ANOVA de Welch constitue une alternative robuste. Elle repose sur la correction de Welch-Satterthwaite qui ajuste les degrés de liberté de la statistique de test sans postuler l'égalité des variances inter-groupes.

```
oneway.test(count ~ spray, data = InsectSprays, var.equal = FALSE)
##  One-way analysis of means (not assuming equal variances)
## data:  count and spray
## F = 36.065, num df = 5.000, denom df = 30.043, p-value = 7.999e-12
```

La statistique de Fisher ajustée vaut $F = 36{,}065$ avec des degrés de liberté corrigés $(5{,}00\,;\,30{,}04)$ et une p-value de $8{,}0 \times 10^{-12}$. La réduction du dénominateur, passant de 66 à 30 degrés de liberté, reflète la correction pour l'hétéroscédasticité. La conclusion demeure inchangée : l'effet du type de pesticide est hautement significatif.

5.4 Test de Kruskal-Wallis

Le test de Kruskal-Wallis est l'équivalent non paramétrique de l'ANOVA. Il raisonne sur les rangs des observations plutôt que sur les valeurs elles-mêmes et ne requiert ni normalité ni homogénéité des variances.

```
# Test de Kruskal-Wallis
kruskal.test(count ~ spray, data = InsectSprays)
## Kruskal-Wallis chi-squared = 54.691, df = 5, p-value = 1.511e-10

# Comparaisons post-hoc par le test de Dunn (correction de Bonferroni)
dunn.test(InsectSprays$count, InsectSprays$spray,
          method = "bonferroni", kw = FALSE, label = TRUE)
```

La statistique de test vaut $\chi^2 = 54{,}69$ avec 5 degrés de liberté et une p-value de $1{,}5 \times 10^{-10}$. Le test post-hoc de Dunn confirme que les sprays C, D et E se différencient significativement des sprays A, B et F dans leur effet sur les populations d'insectes.

5.5 Comparaison synoptique des approches

Table 5.2. Synthèse comparative des six approches statistiques évaluées

Méthode	Hypothèses requises	p-value	Norm.	Homosc.	Avis
ANOVA classique	Normalité ; homoscédasticité	$< 2{\cdot}10^{-16}$	✗	✗	Non validée
$\sqrt{\cdot}$ + ANOVA	Norm. ; homoscéd. sur $\sqrt{Y}$	$< 2{\cdot}10^{-16}$	✓	✓	Recommandée
$\log(\cdot)$ + ANOVA	Norm. ; homoscéd. sur $\log Y$	$< 2{\cdot}10^{-16}$	∼	∼	Partielle
Box-Cox + ANOVA	Norm. ; homoscéd. sur Y^{λ}	$< 2{\cdot}10^{-16}$	✓	✓	Alternative
ANOVA de Welch	Normalité uniquement	$8{,}0{\cdot}10^{-12}$	∼	✓	Partielle
Kruskal-Wallis	Aucune (non paramétrique)	$1{,}5{\cdot}10^{-10}$	✓	✓	Recommandée

5.5.1 Illustration visuelle de l'effet de la transformation

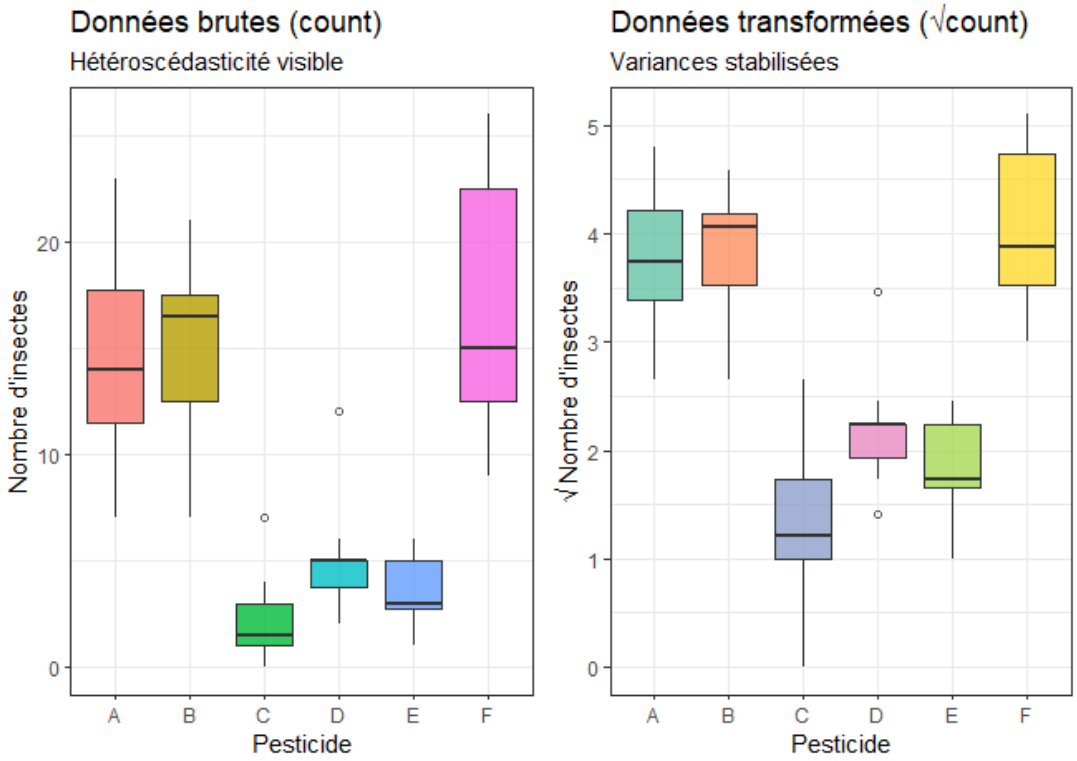


Figure 5.4. Comparaison des boîtes à moustaches avant et après transformation racine carrée

La représentation côte à côte illustre concrètement l'effet de la transformation : les boîtes à moustaches deviennent notablement plus homogènes en taille après transformation, traduisant visuellement la stabilisation des variances. Bien que les six méthodes aboutissent à la même conclusion quant à la significativité de l'effet, la transformation racine carrée suivie de l'ANOVA demeure la méthode la plus rigoureuse et la plus recommandée dans ce contexte.

CONCLUSION

Ce rapport a examiné l'application de l'ANOVA à un facteur à la base de données `InsectSprays` en accordant une attention particulière à la validité des hypothèses du modèle. L'analyse a mis en évidence que les données de comptage violent systématiquement les conditions de normalité et d'homogénéité des variances requises par la théorie. Ces violations, décelées à travers des outils graphiques adaptés puis confirmées formellement par les tests de Shapiro-Wilk et de Levene, s'expliquent par la structure même des données de comptage : le ratio variance sur moyenne, compris entre 1,19 et 2,31 selon le groupe, atteste d'une surdispersion généralisée incompatible avec les postulats du modèle classique. Concernant l'ordre des tests d'homogénéité, le test de Levene ($p = 0{,}004$) constitue la référence la plus fiable dans ce contexte, le test de Bartlett étant anti-conservateur en présence de non-normalité.

Face à ce constat, cinq approches correctives ont été explorées et comparées. Parmi elles, la transformation racine carrée s'est avérée la plus adaptée dans le cas présent, en corrigeant simultanément les deux violations et en permettant une ANOVA valide sur le plan statistique. Cette recommandation est d'ailleurs confirmée *a posteriori* par la transformation de Box-Cox, dont le paramètre optimal $\hat{\lambda} = 0{,}284$ est proche de $0{,}5$, validant théoriquement le choix de $\sqrt{Y}$. Les comparaisons post-hoc de Tukey HSD, qui contrôlent l'erreur familiale globale au niveau 5 % sur l'ensemble des 15 paires, ont mis en évidence deux groupes d'efficacité clairement séparés : les insecticides A, B et F (groupe homogène **a**, moins efficaces) d'une part, et les insecticides C, D et E (groupe homogène **b**, plus efficaces) d'autre part. Le test de Kruskal-Wallis apporte une confirmation non paramétrique indépendante de toute hypothèse distributionnelle, et la convergence de l'ensemble des méthodes renforce la robustesse de cette conclusion.

Sur le plan méthodologique, ce travail illustre l'importance d'un diagnostic préalable rigoureux avant toute interprétation d'un modèle d'analyse de la variance. En perspective, une modélisation par modèle linéaire généralisé à loi de Poisson, voire quasi-Poisson pour les groupes présentant une surdispersion forte comme le spray F, offrirait un cadre théorique encore plus adéquat, en modélisant directement la relation structurelle entre la moyenne et la variance sans recourir à une transformation préalable.

RÉFÉRENCES BIBLIOGRAPHIQUES

- Beall, G. (1942). The Transformation of Data from Entomological Field Experiments. *Biometrika*, 29(3-4), 243–262.
- Box, G.E.P. & Cox, D.R. (1964). An Analysis of Transformations. *Journal of the Royal Statistical Society*, 26(2), 211–252.
- Montgomery, D.C. (2017). *Design and Analysis of Experiments* (9e éd.). Wiley.
- Kutner, M.H., Nachtsheim, C.J., Neter, J. & Li, W. (2005). *Applied Linear Statistical Models* (5e éd.). McGraw-Hill.
- Zar, J.H. (2010). *Biostatistical Analysis* (5e éd.). Prentice Hall.
- R Core Team (2025). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienne, Autriche.
- Fox, J. & Weisberg, S. (2019). *An R Companion to Applied Regression* (3e éd.). Sage Publications.
- Dunn, O.J. (1964). Multiple Comparisons Using Rank Sums. *Technometrics*, 6(3), 241–252.
- BOCO, S.T. & GUEZODJE, P. (2024). *Analyse de la variance avec correction de l'hétérogénéité et de la non normalité*. ENEAM, Bénin.